

PRELIMINARES

→ Teorema de la probabilidad compuesta.

Sean A_1, \dots, A_{n-1} tales que $P\left(\bigcap_{i=1}^{n-1} A_i\right) > 0$, para todo $A_n \in \mathcal{A}$, entonces se verifica la siguiente identidad:

$$P\left(\bigcap_{i=1}^n A_i\right) = P(A_1)P(A_2/A_1)P(A_3/A_1 \cap A_2) \dots P(A_n/A_1 \cap \dots \cap A_{n-1}).$$

→ Teorema de la probabilidad total.

Sea $\{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{A}$ una secuencia de sucesos que define una partición de Ω , siendo $\underbrace{P(A_i)}_{\text{suceso posible}} > 0$, para $i \in \mathbb{N}$, entonces

$$P(B) = \sum_{i=1}^{\infty} P(B/A_i)P(A_i).$$

Recuperamos la probabilidad de B
a partir de las prob. condicionales

→ Teorema de Bayes.

Sea $\{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{A}$ una secuencia de sucesos que define una partición de Ω , siendo $P(A_i) > 0$, para $i \in \mathbb{N}$,

$$P(A_i/B) = \frac{P(B/A_i)P(A_i)}{\sum_{i=1}^{\infty} P(B/A_i)P(A_i)} = \underset{= P(B)}{\cancel{\sum_{i=1}^{\infty} P(B/A_i)P(A_i)}}.$$

→ **Variable aleatoria** *Probabilidad que es v.a. (teoría)*

Una **variable aleatoria** sobre un espacio de probabilidad (Ω, \mathcal{A}, P) es una función medible $X : \Omega \rightarrow \mathbb{R}$, i.e.,

$$X^{-1}(B) \in \mathcal{A}, \quad B \in \mathcal{B}.$$

→ Teorema de Markov.

$$X \geq 0, \exists E[X] \Rightarrow P(X \geq \varepsilon) \leq \frac{E[X]}{\varepsilon}, \quad \varepsilon > 0.$$

→ Desigualdad de Chebychev.

$$\exists E[X^2] \Rightarrow P(|X - E[X]| \geq k) \leq \frac{\text{Var}[X]}{k^2}, \quad k > 0.$$

↑ convergente

Distribución Degenerada

Una v.a. $X : \Omega \rightarrow \mathbb{R}$, tal que $P(X = c) = 1$, para un cierto $c \in \mathbb{R}$, se dice que sigue una **Distribución Degenerada en un punto**. Denotamos

$$X \sim D(c)$$

- Función de distribución:** F_X tal que $F_X(c^-) = 0$, y $F_X(c) = F_X(x) = 1$, para cualquier $x > c$.

$$M_X(t) = E[e^{tX}] = e^{tc} + e^t - 1 \in \mathbb{R}$$

- Función generatriz de momentos:** $M_X(t) = e^{tc}$, $t \in \mathbb{R}$.

- Momentos:** $m_k = c^k$ y $\mu_k = 0$, $\forall k \in \mathbb{N}$.

- Caracterización:** Una variable X es degenerada si y sólo si $\text{Var}(X) = 0$.

$$\begin{aligned} \text{Var}(X) &= E[X^2] - (E[X])^2 = c^2 - c^2 = 0 \\ E[X] &= \frac{\partial}{\partial t} M_X(t) \Big|_{t=0} = c \\ E[X^2] &= \frac{\partial^2}{\partial t^2} M_X(t) \Big|_{t=0} = c^2 \end{aligned}$$

Distribución de Benoulli

Una v.a. $X : \Omega \rightarrow \mathbb{R}$, se dice que sigue una **Distribución Bernoulli** de parámetro p si y solo toma los valores 0 y 1 con probabilidades $1 - p$ y p respectivamente. Denotamos

$$X \sim B(1, p), 0 < p < 1$$

- Función Masa de Probabilidad:** $P(X = x) = p^x(1-p)^{1-x}$, $x = 0, 1$. *easy*
- Función de Distribución:** $F_X(x) = 0$, para $x < 0$, $F_X(x) = 1 - p$, para $0 \leq x < 1$, y $F_X(x) = 1$, para $x \geq 1$.
- Función Generatriz de Momentos:** $M_X(t) = pe^t + (1-p)$, $t \in \mathbb{R}$.
- Momentos:** $m_k = p$, y $\mu_k = (1-p)^k p + (-p)^k (1-p)$, para $k \in \mathbb{N}$.
- Media:** $E[X] = p$.
- Varianza:** $\text{Var}(X) = p(1-p)$.

Distribución Uniforme Discreta

Una v.a. $X : \Omega \rightarrow \mathbb{R}$, tal que $P(X = x_i) = \frac{1}{n}$, $i = 1, \dots, n$, se dice que sigue una **Distribución Uniforme en n puntos**. Denotamos

$$X \sim \mathcal{U}(x_1, \dots, x_n), x_i \in \mathbb{R}$$

- Función de distribución:**

$$F_X(x) = \begin{cases} 0 & x < x_1 \\ \frac{i-1}{n} & x_1 \leq x < x_i, i = 2, \dots, n \\ 1 & x \geq x_n \end{cases}$$

- Función generatriz de momentos:** $M_X(t) = \frac{\sum_{i=1}^n x_i^k}{n}$, $t \in \mathbb{R}$.

- Momentos:** $m_k = \frac{\sum_{i=1}^n x_i^k}{n}$ y $\mu_k = \frac{\sum_{i=1}^n (x_i - m_1)^k}{n}$, $\forall k \in \mathbb{N}$.

- Esperanza matemática de una función medible:** $E[g(X)] = \frac{1}{n} \sum_{i=1}^n g(x_i)$.

- Casos especiales:** $E[X] = \bar{x}$, y $\text{Var}(X) = S^2$, denotando, como es usual, por S^2 la varianza muestral.

Distribución de Poisson

Una variable aleatoria, asociada a la **ocurrencia de un número determinado de eventos durante cierto período de tiempo** (con probabilidad de ocurrencia pequeña) se dice que sigue una **Distribución de Poisson** de parámetro λ . Denotamos

$$X \sim \mathcal{P}(\lambda), (\lambda > 0)$$

También es conocida como **Ley de los sucesos raros**.

- λ expresa la frecuencia media de ocurrencia de un evento, esto es, el número de veces que se espera que ocurra el evento durante un intervalo de tiempo dado.
- Función Masa de Probabilidad:** $P(X = x) = e^{-\lambda} \frac{\lambda^x}{x!}$, $x = 0, 1, 2, \dots$ *(puede tener valores negativos)*
- Aproximación mediante el modelo Binomial:** Cuando el número n de pruebas de Bernoulli tiende a ser infinito para un suceso con escasa probabilidad de ocurrencia, la distribución Binomial aproxima a una distribución de Poisson (ley de los sucesos raros). *una Poisson es un límite para una Binomial de sucesos raros*
- Función Generatriz de Momentos:** $M_X(t) = \exp(\lambda(e^t - 1))$, $t \in \mathbb{R}$. *exp(e^t - 1) = e^{\lambda(e^t - 1)}*
- Media y Varianza:** $E[X] = \text{Var}(X) = \lambda$. *únicamente en lo que estos valores coinciden*

Distribución Geométrica

Una variable aleatoria, asociada al **número de fracasos, en sucesivas repeticiones independientes de una prueba de Bernoulli con probabilidad de éxito p , antes de que ocurra el primer éxito** se dice que sigue una **Distribución Geométrica** de parámetro p , $(0 < p < 1)$. Denotamos

$$X \sim \mathcal{G}(p), (0 < p < 1)$$

$$P(X = x) = F_X(x) - F_X(x-1)$$

$$P(X = x) = (1-p)^x p^1 - (1-p)^{x-1} p^1$$

- Función de Distribución:** $F_X(x) = 0$, para $x < 0$, y $F_X(x) = 1 - (1-p)^{x+1}$ para $x \geq 0$.

- Función Generatriz de Momentos:** $M_X(t) = \frac{p}{1-(1-p)e^t}$, $t < -\ln(1-p)$.

$$E[X] = \frac{1-p}{p}$$

$$\text{Var}(X) = \frac{1-p}{p^2}$$

- Propiedad de falta de memoria:**

$$P(X \leq h+k/X \leq h) = P(X \leq k) \quad \forall h, k \in \mathbb{N} \cup 0.$$

- Caracterización:** Es la única distribución con valores enteros positivos que verifica la propiedad de falta de memoria.

Distribución Binomial Negativa

Una variable aleatoria, asociada al **número de fracasos, en sucesivas repeticiones independientes de una prueba de Bernoulli con probabilidad de éxito p , antes de que ocurra el k -ésimo éxito** se dice que sigue una **Distribución Binomial Negativa** de parámetros n y p , $(0 < p < 1)$. Denotamos

$$X \sim \mathcal{BN}(k, p), k \in \mathbb{N}, (0 < p < 1)$$

- La v.a. $X + k$ sigue una **Distribución de Pascal o Tiempo de Espera**. Indica el número de pruebas hasta el k -ésimo éxito.

- Función Masa de Probabilidad:**

$$P(X = x) = \binom{x+k-1}{x} (1-p)^x p^k, \quad x \in \mathbb{N}$$

- Función Generatriz de Momentos:** $M_X(t) = \left[\frac{p}{1-(1-p)e^t} \right]^k$, $t < -\ln(1-p)$.

- E[X]** = $\frac{k(1-p)}{p}$ *igual que aves pero null n*

- Var(X)** = $\frac{k(1-p)}{p^2}$ *igual que aves pero null n*

(15, 17)

Distribución Hipergeométrica

→ va variando la prob de éxito

Si se considera una población de tamaño N y una subpoblación de tamaño N_1 , y se extrae una muestra aleatoria de tamaño n , sin reemplazamiento o simultáneamente, una v.a. X que describe el **número de individuos de la muestra que pertenecen a la subpoblación** se dice que sigue una **Distribución Hipergeométrica** de parámetros N, N_1 y n . Denotamos

$$X \sim \mathcal{H}(N, N_1, n); N, N_1, n \in \mathbb{N}, N_1, n \leq N$$

EJEMPLO: $\begin{array}{c} N=10 \\ N_1=5 \\ \text{Samp. Reces: } N=5 \\ \text{Samp. Reces: } N=3 \end{array}$

- Función Masa de Probabilidad:**

$$P(X = x) = \frac{\binom{N_1}{x} \binom{N-N_1}{n-x}}{\binom{N}{n}}, \quad x = 0, \dots, n, \quad x \leq N_1, \quad n-x \leq N-N_1.$$

- E[X]** = $n \frac{N_1}{N}$ *→ igual que prob de éxito*

- Var(X)** = $n \frac{N_1}{N} \left(1 - \frac{N_1}{N}\right) \frac{N-N_1}{N-1} \cdot \frac{n-x}{n-1}$ *igual que prob de éxito*

- Aproxima** a una distribución Binomial $B(n, p)$ cuando $N, N_1 \rightarrow \infty$, con $N_1/N \rightarrow p$, y siendo n el parámetro de la Hipergeométrica, que define el número de pruebas de Bernoulli en el modelo Binomial que approxima.

TEMA 1

Definición

La **distribución uniforme continua** sobre un intervalo (a, b) , se caracteriza por **tomar valores en dicho intervalo y tener una densidad de probabilidad constante**.

En concreto,

$$X \sim \mathcal{U}(a, b), \quad a < b, \Leftrightarrow f_X(x) = \frac{1}{b-a}, \quad \forall x \in (a, b).$$

Función de distribución

Para cualquier $x \in (a, b)$, se tiene

$$F_X(x) = \int_a^x f_X(y) dy = \int_a^x \frac{1}{b-a} dy = \frac{x}{b-a} - \frac{a}{b-a} = \frac{x-a}{b-a}. \quad \begin{matrix} \text{rectangular} \\ \text{esta es la probabilidad} \\ \text{de que el valor sea menor} \\ \text{que x} \end{matrix}$$

Para $x < a$, $F_X(x) = 0$ y para $x \geq b$, $F_X(x) = 1$, según se deriva de la definición de función de distribución de una variable aleatoria continua (ver capítulo de Preliminares).

Función generatriz de momentos

$$M_X(t) = E[e^{tX}] = \int_a^b \frac{e^{tx}}{b-a} dx = \frac{e^{tb} - e^{ta}}{t(b-a)}, \quad t \neq 0; \quad M_X(t) = 1, t = 0.$$

Distribución Normal

$X \sim \mathcal{N}(\mu, \sigma^2); \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}_+$

Se dice que una **variable aleatoria (v.a.) continua X se distribuye según una normal** de parámetros μ y σ^2 si su **función de densidad f_X** viene dada por la siguiente expresión:

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad x \in \mathbb{R}$$

Mediante el procedimiento de **tipificación** se tiene que,

$$X \sim \mathcal{N}(\mu, \sigma^2) \Leftrightarrow \frac{X-\mu}{\sigma} \sim \mathcal{N}(0, 1)$$

Proposición

- (i) $X \sim \mathcal{N}(0, 1) \Leftrightarrow M_X(t) = E[e^{tX}] = e^{\frac{t^2}{2}}$. se define en todo \mathbb{R}
- (ii) $X \sim \mathcal{N}(\mu, \sigma^2) \Leftrightarrow M_X(t) = E[e^{tX}] = e^{\mu t + \frac{\sigma^2 t^2}{2}}$.

Poisson y Binomial → corrección por cont.

Definición

Una v.a X se dice que sigue una **distribución exponencial** si:

$$X \sim \exp(\lambda) \Leftrightarrow f_X(x) = \lambda e^{-\lambda x}, \quad \forall x \geq 0.$$

se usa para observación programada... por ejemplo

Función de distribución

$$F_X(x) = \int_0^x \lambda e^{-\lambda x} dx = 1 - e^{-\lambda x}, \quad x \geq 0.$$

Función generatriz de momentos

$$\begin{aligned} M_X(t) &= E[e^{tX}] = \int_0^\infty \lambda e^{\lambda(t-\lambda)} dx = \left[\frac{\lambda e^{\lambda(t-\lambda)}}{t-\lambda} \right]_{x=0}^{x=\infty} \\ &= -\frac{\lambda}{t-\lambda} = \left(1 - \frac{t}{\lambda}\right)^{-1}, \quad t < \lambda. \end{aligned}$$

Definición

Indica el **tiempo aleatorio transcurrido hasta la ocurrencia del n -ésimo suceso aleatorio**, i.e., $X_i \sim \exp(\lambda)$, $i = 1, \dots, n$, mutuamente independientes.

$$\sum_{i=1}^n X_i = E \sim \mathcal{E}(n, \lambda).$$

cuando $n=1$, $E \sim \exp$

cuando $n \in \mathbb{N}$, $E = \infty$

Para $n \in \mathbb{N} - \{0\}$, y $\lambda > 0$, la densidad de probabilidad f_E de la v.a. E se define como sigue

$$f_E(x) = \frac{\lambda^n}{\Gamma(n)} x^{n-1} e^{-\lambda x}, \quad \Gamma(n) = (n-1)! \quad x \in \mathbb{R}_+.$$

Función generatriz de momentos

$$M_E(t) = \left[\left(1 - \frac{t}{\lambda}\right) \right]^{-n}, \quad t < \lambda.$$

Función gamma, $\Gamma(u)$

Previamente al estudio de la distribución gamma, se define la **función gamma**, representada por $\Gamma(u)$ como:

$$\Gamma(u) = \int_0^\infty x^{u-1} e^{-x} dx, \quad u > 0.$$

lo vimos en ANII

Distribución Gamma

$X \sim \Gamma(u, \lambda); u, \lambda \in \mathbb{R}_+$

Es una **extensión de la distribución de Erlang**, definida cuando el parámetro n no es un número natural sino que es un número real. Es decir, se obtiene ampliando el espacio paramétrico de la distribución de Erlang.

$$X \sim \Gamma(u, \lambda), \quad u, \lambda \in \mathbb{R}_+ \Leftrightarrow f_X(x) = \frac{\lambda^u}{\Gamma(u)} x^{u-1} e^{-\lambda x}, \quad x > 0.$$

Función generatriz de momentos

$$M_X(t) = \left[\left(1 - \frac{t}{\lambda}\right) \right]^{-u}, \quad t < \lambda.$$

ACTIVIDAD
VOLUNTARIA
(hacer)

Función Beta, $\beta(p, q)$

Previamente al estudio de la distribución beta, se define la **función beta**, representada por $\beta(p, q)$ como:

$$\beta(p, q) = \int_0^1 x^{p-1} (1-x)^{q-1} dx.$$

Distribución Beta

$X \sim \beta(p, q); p, q > 0$

Una v.a. X sigue una **distribución beta** de parámetros p y q si:

$$X \sim \beta(p, q) \Leftrightarrow f_X(x) = \frac{1}{\beta(p, q)} x^{p-1} (1-x)^{q-1}, \quad x \in (0, 1), \quad p, q > 0.$$

TEMA 2

Teorema de medibilidad.

$X = (X_1, \dots, X_n)$ es un vector aleatorio sobre (Ω, \mathcal{A}, P) si y sólo si X_i es una variable aleatoria sobre (Ω, \mathcal{A}, P) , para $i = 1, \dots, n$.

→ (iii) Sean $\varepsilon_1, \varepsilon_2 > 0$

$$F(x+\varepsilon_1, y+\varepsilon_2) - F(x, y+\varepsilon_2) - F(x+\varepsilon_1, y) + F(x, y) \geq 0$$

Buscamos un punto contraejemplo que no lo verifique. Para ello, sabiendo como es F , necesitamos que los tres primeros sumandos sean 1 y el último se curule (que $a+\varepsilon > a$, $\varepsilon > 0$). Fijamos $\varepsilon_1=2$, $\varepsilon_2=1$, $\in \mathbb{R}^+$. Tomamos $x=-1$, $y=0$. Así:

$$\begin{aligned} F(-1+2, 0+1) &= 1 \\ F(-1, 0+1) &= 1 \\ F(-1, 0) &= 0 \\ F(-1+2, 0) &= 1 \end{aligned} \quad \left. \begin{array}{l} (-1, 0) \text{ sirve como} \\ \text{contraejemplo} \end{array} \right.$$

Concluimos que F no es función de distribución ✓

Función de densidad de $Y = g(X)$, X continuo y Y continuo

Sea $X = (X_1, \dots, X_n)$ en (5) es una variable aleatoria n -dimensional continua, con función de densidad de probabilidad f_X . Supongamos que $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es una función medible satisfaciendo las siguientes condiciones:

(i) g es derivable en todos los argumentos

(ii) g es inyectiva ($g^{-1} : g(E_X) \rightarrow E_X$, es una aplicación). Es decir, $\forall y \in g(E_X)$, existe un único $x = (x_1, \dots, x_n) \in E_X$, tal que $g(x) = g(x_1, \dots, x_n) = y$. Dado que x está únicamente determinado por y , utilizaremos la notación

$$g^{-1}(y) = x(y) = (x_1(y), \dots, x_n(y)).$$

(iii) El jacobiano de g^{-1} es no nulo, i.e., para cualquier $y \in g(E_X)$,

$$J(y) = \det \begin{bmatrix} \frac{\partial x_1(y_1, \dots, y_n)}{\partial y_1} & \dots & \frac{\partial x_1(y_1, \dots, y_n)}{\partial y_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial x_n(y_1, \dots, y_n)}{\partial y_1} & \dots & \frac{\partial x_n(y_1, \dots, y_n)}{\partial y_n} \end{bmatrix} = \begin{vmatrix} \frac{\partial x_1(y_1, \dots, y_n)}{\partial y_1} & \dots & \frac{\partial x_1(y_1, \dots, y_n)}{\partial y_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial x_n(y_1, \dots, y_n)}{\partial y_1} & \dots & \frac{\partial x_n(y_1, \dots, y_n)}{\partial y_n} \end{vmatrix} \neq 0$$

Bajo las condiciones (i)-(iii), $Y = g(X)$ es una variable aleatoria n -dimensional continua, cuya función de densidad f_Y viene dada por:

$$f_Y(y) = f_X(g^{-1}(y)) |J(y)|, \quad \forall y \in g(E_X)$$

Caracterización de vector aleatorio discreto

Un vector aleatorio $X = (X_1, \dots, X_n) : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}^n, \mathcal{B}^n)$ es discreto si y sólo si, para $i = 1, \dots, n$, $X_i : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}, \mathcal{B})$ es una variable aleatoria discreta unidimensional.

Demostración (\Rightarrow)

Supongamos que X es un vector aleatorio discreto, i.e., $\exists E_X \subset \mathbb{R}^n$ tal que $P(X \in E_X) = 1$. Definamos el subconjunto

$$\Psi_R^i(E_X) = \{y \in \mathbb{R} : \exists x \in E_X, x = (x_1, \dots, x_i = y, \dots, x_n)\}.$$

Dicho conjunto representa la proyección de E_X sobre la i -ésima componente. Dado que E_X es numerable, $\Psi_R^i(E_X)$ es también numerable. Adicionalmente,

$$P(X_i \in \Psi_R^i(E_X)) = P(X_1 \in \mathbb{R}, \dots, X_i \in \Psi_R^i(E_X), \dots, X_n \in \mathbb{R})$$

$$\stackrel{\text{dijo que } E \text{ es nro}}{\geq} P(X \in E_X) = 1. \quad \text{con lo que generalizamos}$$

Por tanto, X_i es una variable aleatoria unidimensional discreta, para $i = 1, \dots, n$.

Demostración (\Leftarrow)

Supongamos ahora que X_i es una variable aleatoria unidimensional discreta, para $i = 1, \dots, n$, i.e., existe un subconjunto numerable $E_{X_i} \subset \mathbb{R}$, tal que $P(X_i \in E_{X_i}) = 1$, para $i = 1, \dots, n$. Por tanto el subconjunto de \mathbb{R}^n dado por $E_{X_1} \times \dots \times E_{X_n}$ es también numerable. Se tiene entonces,

$$\begin{aligned} P(X = (X_1, \dots, X_n) \in E_{X_1} \times \dots \times E_{X_n}) &= P(X_1 \in E_{X_1}, \dots, X_n \in E_{X_n}) \\ &= P\left(\bigcap_{i=1}^n \{X_i \in E_{X_i}\}\right) \geq 1 - \sum_{i=1}^n P\left(\{X_i \in \mathbb{R} \setminus E_{X_i}\}\right) \stackrel{\text{desigualdad de Boole}}{=} 1 - \sum_{i=1}^n P(X_i \in \mathbb{R} \setminus E_{X_i}) = 1 \end{aligned}$$

Caracterización de vector aleatorio continuo

Sea $X = (X_1, \dots, X_n) : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}^n, \mathcal{B}^n, P_X)$ es un vector aleatorio continuo. Entonces, $X_i : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}, \mathcal{B}, P_{X_i})$ es una variable aleatoria continua, para $i = 1, \dots, n$.

Demostración

Para cada $i = 1, \dots, n$,

$$\begin{aligned} F_{X_i}(x_i) &= P(X_i \leq x_i) = P(X_1 \in \mathbb{R}, \dots, X_i \leq x_i, \dots, X_n \in \mathbb{R}) \\ &= \int_{-\infty}^{\infty} \dots \int_{-\infty}^{x_i} \dots \int_{-\infty}^{\infty} f_X(t_1, \dots, t_n) dt_1 \dots dt_n \\ &= \int_{-\infty}^{x_i} \left[\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f_X(t_1, \dots, t_n) dt_1 \dots dt_{i-1} dt_{i+1} \dots dt_n \right] dt_i \end{aligned}$$

Definimos entonces la función $f_{X_i} : \mathbb{R} \rightarrow \mathbb{R}$ dada por

$$f_{X_i}(t_i) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f_X(t_1, \dots, t_i, \dots, t_n) dt_1 \dots dt_{i-1} dt_{i+1} \dots dt_n.$$

Dicha función es no negativa e integrable y su integral sobre \mathbb{R} vale uno. Adicionalmente, se tiene la siguiente igualdad:

$$F_{X_i}(x_i) = \int_{-\infty}^{x_i} f_{X_i}(t_i) dt_i.$$

Por tanto, X_i es de tipo continuo con densidad de probabilidad f_{X_i} .

Contraejemplo

Se considera seguidamente un contraejemplo, donde se observa que un conjunto finito de variables continuas no definen necesariamente un vector aleatorio continuo.

Sea (X_1, X_2) un vector aleatorio tal que X_1 es de tipo continuo y $X_2 = 2X_1 + k$, para un cierto $k > 0$.

Entonces (X_1, X_2) no es un vector aleatorio continuo, ya que si lo fuera

$$P(X_2 = 2X_1 + k) = \int_{\{(x_1, x_2) \in \mathbb{R}^2 : x_2 = 2x_1 + k\}} f_{(X_1, X_2)}(t_1, t_2) dt_1 dt_2 = 0.$$

Sin embargo, a partir de la definición de dicho vector se tiene:

$$P(X_2 = 2X_1 + k) = 1.$$

Distribuciones el máximo y del mínimo

Notación

Sea $X = (X_1, \dots, X_n) : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}^n, \mathcal{B}^n, P_X)$ un vector aleatorio n -dimensional. Se definen las variables aleatorias unidimensionales

$$\max(X_1, \dots, X_n) : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}, \mathcal{B})$$

$$\min(X_1, \dots, X_n) : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}, \mathcal{B})$$

cuyas funciones de distribución se definen como sigue: para cualquier $y \in \mathbb{R}$,

$$\begin{aligned} F_{\max(X_1, \dots, X_n)}(y) &= P(\max(X_1, \dots, X_n) \leq y) \\ &= P(X_1 \leq y, \dots, X_n \leq y) = F_X(y, \dots, y) \end{aligned}$$

$$F_{\min(X_1, \dots, X_n)}(y) = P(\min(X_1, \dots, X_n) \leq y)$$

$$= 1 - P(\min(X_1, \dots, X_n) > y) = 1 - P(X_1 > y, \dots, X_n > y)$$

$$= 1 - P_X((y, \infty) \times \dots \times (y, \infty)).$$

Distribuciones el máximo y del mínimo

La función de distribución conjunta de la variable aleatoria bidimensional

$$(Z, T) = (\min(X_1, \dots, X_n), \max(X_1, \dots, X_n)),$$

viene dada por

$$F_{(Z, T)}(x, y) = \begin{cases} F_X(y, \dots, y), & y \leq x \\ F_X(y, \dots, y) - P(x < X_1 \leq y, \dots, x < X_n \leq y), & y > x \end{cases}$$

En este espacio, la desigualdad de Cauchy-Schwarz indica que:

$$[E(XY)]^2 \leq E[X^2]E[Y^2], \quad \forall X, Y \in L^2(\Omega, \mathcal{A}, P).$$

TEMA 4

Caso especial: varianza condicionada

Supongamos que X , tal que $E[X^2]$, e Y son dos variables aleatorias sobre el mismo espacio de probabilidad, entonces:

- $\text{Var}(X/Y)$, y $\text{Var}(X/Y) \geq 0$.
- $\text{Var}(X/Y) = E[X^2/Y] - [E(X/Y)]^2$.
- Descomposición de la varianza: si $\text{Var}(E[X/Y])$, y $E[\text{Var}(X/Y)]$, entonces:

$$\text{Var}(X) = \text{Var}(E[X/Y]) + E[\text{Var}(X/Y)].$$

Demostración:

$$\begin{aligned} \text{Var}(X) &= E[(X - E[X])^2] = E[E[(X - E[X])^2/Y]] \quad (\text{Prop. (v)}) \\ &= E[E[(X^2 + (E[X])^2 - 2XE[X])/Y]] \quad \xrightarrow{\text{desarrollar}} E[2E[X]^2/Y] = 2E[X^2/Y] \\ &= E[X^2/Y] + (E[X])^2 - 2E[X]E[X/Y] \quad (\text{linealidad}) \\ &= E[X^2/Y] - (E[X/Y])^2 + (E[X/Y])^2 + (E[X])^2 - 2E[X]E[X/Y] \\ &= E[\text{Var}(X/Y)] + E[(E[X/Y] - E[X])^2] \quad (\text{desarrollar}) \\ &= E[\text{Var}(X/Y)] + \text{Var}(E[X/Y]). \quad (\text{Prop. (v)} \text{ y def. momento centrado condicionado de orden dos}) \end{aligned}$$

La función φ_{opt} , que minimiza el E.C.M., en la aproximación de Y mediante una función de X viene dada por:

$$\varphi_{\text{opt}}(X) = E[Y/X].$$

$$\begin{aligned} \text{E.C.M.}(\varphi(X)) &= E[(Y - E[Y/X])^2] \\ &= E[E[(Y - E[Y/X])^2/X]] = E[\text{Var}(Y/X)]. \\ &= E[Y^2] - E[(E(Y/X))^2] \end{aligned}$$

- Si X e Y son independientes, las curvas de regresión son rectas paralelas a los ejes: $y = E[Y]$ y $x = E[X]$.

En este caso estimamos una variable, sin observar la otra, mediante su esperanza y el E.C.M. es su varianza.

Se definen las razones de correlación de X sobre Y , $\eta_{X/Y}^2$ y de Y sobre X , $\eta_{Y/X}^2$, como sigue:

$$\frac{\text{razón}}{\text{bondad}} \eta_{X/Y}^2 = \frac{\text{Var}(E[X/Y])}{\text{Var}(X)} = 1 - \frac{\text{Var}(X/Y)}{\text{Var}(X)} \quad \begin{array}{l} \xrightarrow{\text{modelos}} \text{lleva} \\ \xrightarrow{\text{var que expone}} \text{mala} \end{array}$$

- La razón de correlación es una medida adimensional que representa la proporción de varianza de la variable dependiente que queda explicada por la función de regresión.

Si $\eta_{X/Y}^2 = 0$ y $\eta_{Y/X}^2 = 0$, las curvas de regresión de X/Y e Y/X coinciden respectivamente con las rectas $x = E[X]$ e $y = E[Y]$.

- $\eta_{X/Y}^2 = 1 \Leftrightarrow X$ dependen funcionalmente de Y . \rightarrow Ambas \Rightarrow dep. funcional recip.

Planteamiento de la regresión lineal de Y sobre X (equivalentemente para X sobre Y)

Intentamos resolver el problema de predecir, por mínimos cuadrados, los valores de una variable Y a partir de una función lineal de otra X . En este sentido se busca una función $\varphi_{\text{opt}}^L(X)$ que minimice el E.C.M.

$$\varphi_{\text{opt}}^L(X) = \min_{a,b} E[(Y - aX - b)^2].$$

El problema se reduce a obtener a y b que minimicen $L = E[(Y - aX - b)^2]$.

$$L = E[(Y - aX - b)^2] = E[Y^2] + a^2E[X^2] + b^2 + 2abE[X] - 2aE[XY] - 2bE[Y]$$

Derivando respecto a a y b e igualando a cero, se obtiene el siguiente sistema de ecuaciones denominado sistema de **Ecuaciones Normales**:

$$\left. \begin{array}{l} aE[X^2] + bE[X] = E[XY] \\ aE[X] + b = E[Y] \end{array} \right\}$$

cuya solución es $a = \frac{\text{Cov}(X,Y)}{\text{Var}(X)}$ y $b = E[Y] - aE[X]$. \rightarrow MÁS FÁCIL DE TRABAJAR QUE LA CURVA

Regresión mínimo-cuadrática, cuando φ^L es una recta ($R_{Y/X}$)

A partir de las soluciones de las ecuaciones normales anteriores se tiene lo siguiente.

En la regresión lineal mínimo cuadrática de Y sobre X ,

$$Y \approx \varphi_{\text{opt}}^L(X) = \min_{a,b} E[(Y - aX - b)^2] = E[Y] + \frac{\text{Cov}(X,Y)}{\text{Var}(X)}(X - E[X]).$$

Esta expresión recibe el nombre de **Recta de Regresión de Y sobre X** .

$$y - E[Y] = \frac{\text{Cov}(X,Y)}{\text{Var}(X)}(x - E[X]).$$

El E.C.M asociado viene dado por: (Ejercicio voluntario)

$$E.C.M.(\varphi_{\text{opt}}^L(X)) = \text{Var}(Y) - \frac{[\text{Cov}(X,Y)]^2}{\text{Var}(X)}.$$

Por tanto, $\text{Var}(Y) = \text{Var}(\varphi_{\text{opt}}^L(X)) + E.C.M.(\varphi_{\text{opt}}^L(X))$.

Las rectas de regresión se cortan en el punto $(E[X], E[Y])$.

BONDAD DEL AJUSTE

Coefficiente de determinación lineal

Una medida de la asociación lineal de las variables viene determinada por el **coeficiente de determinación lineal** $\rho_{X,Y}^2$, se define como:

$$\rho_{X,Y}^2 = \frac{[\text{Cov}(X,Y)]^2}{\text{Var}(X)\text{Var}(Y)} \left(= \frac{\text{Var}(\varphi_{\text{opt}}^L(X))}{\text{Var}(Y)} = \frac{\text{Var}(\varphi_{\text{opt}}^L(Y))}{\text{Var}(X)} \right).$$

Observación:

• Se deben considerar los momentos de orden dos.

• Dependiendo de la definición, se aplica el resultado.

Tal y como los razones de correlación, el coeficiente de determinación lineal es una medida de la bondad del ajuste lineal, o lo que es lo mismo, mide la proporción de varianza de explicada por el modelo de regresión lineal.

$$(ii). \rho_{X,Y}^2 = \gamma_{X,Y}\gamma_{Y,X}$$

- $\rho_{X,Y}^2 = 0 \Leftrightarrow$ Las rectas de regresión de Y/X y de X/Y son respectivamente $y = E[Y]$, y $x = E[X]$.

$$(vi). \rho_{X,Y}^2 \leq \eta_{Y/X}^2 \text{ y } \rho_{X,Y}^2 \leq \eta_{X/Y}^2. \quad \text{Significó que la curva siempre crece mejor o igual que las rectas.}$$

Las desigualdades anteriores (prop. (vi)) se convierten en igualdades si y sólo si las curvas de regresión coinciden con las correspondientes rectas de regresión.

Coefficiente de correlación lineal

Independientemente de que el coeficiente de determinación lineal ofreca información acerca de la bondad del ajuste del modelo lineal, la medida de correlación por excelencia es el **coeficiente de correlación lineal**, ya que también proporciona información, no sólo de la fuerza de asociación, sino también de su sentido.

Se define el coeficiente de correlación lineal $\rho_{X,Y}$, como:

$$\rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$$

- $\rho_{X,Y} = 0$ (variables incorreladas linealmente) \Leftrightarrow Las rectas de regresión de Y/X y de X/Y son respectivamente $y = E[Y]$, y $x = E[X]$.

- Si X e Y son independientes, entonces $\rho_{X,Y} = 0$ (el recíproco no es cierto)

- $|\rho_{X,Y}| = 1 \Leftrightarrow$ Existe dependencia funcional lineal (positiva o negativa, en función del signo) entre X e Y .

- $|\rho_{X,Y}| = 1 \Leftrightarrow$ Las dos rectas de regresión coinciden entre sí y con la recta de dependencia, además de con las curvas de regresión.

- $\rho_{X,Y} = 1$ la dependencia lineal es exacta y positiva (las dos v.a. crecen o decrecen de forma simultánea).

- $\rho_{X,Y} = -1$ la dependencia lineal es exacta y negativa (cuando una v.a crece la otra decrece y viceversa).

TEMA 5

Distribución multinomial

Consideramos el vector aleatorio $(X_1, X_2, \dots, X_{k+1})$ cuyas componentes X_i cuentan el número de veces que ocurre el suceso A_i , $\forall i = 1, 2, \dots, k+1$, de modo que X_{k+1} queda completamente determinado por $X_{k+1} = n - \sum_{i=1}^k X_i$.

Entonces se dice que (X_1, X_2, \dots, X_k) sigue una distribución multinomial k -dimensional con parámetros n y p_1, \dots, p_k , que denotamos,

$$(X_1, \dots, X_k) \sim M_k(n; p_1, \dots, p_k),$$

si y sólo si su función masa de probabilidad k -dimensional viene dada por:

$$P(X_1 = x_1, \dots, X_k = x_k) = \frac{n!}{x_1! \cdots x_k! (n - \sum_{i=1}^k x_i)!} p_1^{x_1} \cdots p_k^{x_k} \left(1 - \sum_{i=1}^k p_i\right)^{n - \sum_{i=1}^k x_i},$$

donde $n \in \mathbb{N}$, $0 < p_i < 1$, $i = 1, \dots, k$, $\sum_{i=1}^k p_i < 1$, $x_i \in \{0, \dots, n\}$, y $\sum_{i=1}^k x_i \leq n$.

Función generatriz de momentos

$$\begin{aligned} M_{X_1, \dots, X_k}(t_1, \dots, t_k) &= E \left[\exp \left(\sum_{i=1}^k t_i X_i \right) \right] \\ &= \left(p_1 e^{t_1} + \cdots + p_k e^{t_k} + \left(1 - \sum_{i=1}^k p_i\right) \right)^n, \quad t_1, \dots, t_k \in \mathbb{R}. \end{aligned}$$

En particular, para las **marginales unidimensionales** se cumple:

$$X_i \sim B(n, p_i), \quad i = 1, \dots, k.$$

En particular, las **condicionadas unidimensionales** cumplen:

$$X_i/X_j = x_j \sim B\left(n - x_j, \frac{p_i}{1 - p_j}\right), \quad i, j = 1, \dots, k; \quad i \neq j.$$

Vector de medias y covarianzas

Sea $X = (X_1, \dots, X_k)$, vector aleatorio k -dimensional, con distribución multinomial con parámetros n , y , p_1, \dots, p_k . Se tiene entonces:

- i). $E[X] = (np_1, np_2, \dots, np_k)$
- ii). $Cov(X_i, X_j) = -np_i p_j, \forall i \neq j$

Regresión y correlación para el caso bidimensional

- La **curva (recta) de regresión** de X_i/X_j , viene dada por

$$x_i = \frac{np_i}{1 - p_j} - \frac{p_i}{1 - p_j} x_j.$$

- Las **razones de correlación**, que coinciden con el **coeficiente de determinación**, vienen dadas por:

$$\eta_{X_i/X_j}^2 = \eta_{X_j/X_i}^2 = \rho_{X_i X_j}^2 = \frac{p_i p_j}{(1 - p_i)(1 - p_j)}, \quad i \neq j, \quad i, j \in \{1, \dots, k\}.$$

- El **coeficiente de correlación lineal** viene dado por

$$\rho_{X_i X_j} = -\sqrt{\frac{p_i p_j}{(1 - p_i)(1 - p_j)}}, \quad i \neq j, \quad i, j \in \{1, \dots, k\}.$$

Distribución Normal Bidimensional

Se dice que (X_1, X_2) se distribuye según una **normal bidimensional** con **vector de medias** $\mu = (\mu_1, \mu_2)$ y con **matriz de varianzas-covarianzas**

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_1 \sigma_2 \rho \\ \sigma_1 \sigma_2 \rho & \sigma_2^2 \end{pmatrix},$$

si su **función de densidad de probabilidad** viene dada por:

$$f_{(X_1, X_2)}(x_1, x_2) = \frac{1}{2\pi |\det(\Sigma)|^{1/2}} e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)}$$

$$= \frac{1}{2\pi \sigma_1 \sigma_2 \sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)} \left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho \left(\frac{x_1-\mu_1}{\sigma_1} \right) \left(\frac{x_2-\mu_2}{\sigma_2} \right) \right]},$$

donde $x = (x_1, x_2) \in \mathbb{R}^2$, σ_i^2 es la varianza de X_i , $i = 1, 2$, y ρ es el coeficiente de correlación lineal de X e Y .

Marginales y condicionadas

Ambas distribuciones, **marginales y condicionadas**, son **normales**.

- En el caso de las **marginales**, se tiene

$$X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2), \quad X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2).$$

- Para las **condicionadas** se obtienen las siguientes distribuciones normales:

$$X_1/X_2 = x_2 \sim \mathcal{N}\left(\mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2), \sigma_1^2(1 - \rho^2)\right)$$

$$X_2/X_1 = x_1 \sim \mathcal{N}\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right)$$

$$\begin{aligned} f_{X_1/X_2=x_2}(x_2) &= \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_2}(x_2)} = \frac{\frac{1}{\sqrt{2\pi\sigma_2}} e^{-\frac{1}{2}(\frac{(x_2-\mu_2)^2}{\sigma_2^2})}}{\sqrt{2\pi\sigma_1}\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)} \left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho \left(\frac{x_1-\mu_1}{\sigma_1} \right) \left(\frac{x_2-\mu_2}{\sigma_2} \right) \right]} = \\ &= \frac{1}{\sqrt{2\pi\sigma_1}\sqrt{1-\rho^2}} e^{-\frac{1}{2\sigma_1^2(1-\rho^2)} \left[x_1 - \mu_1 - \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2) \right]^2} \end{aligned}$$

$$X_2/X_1=x_1 \sim \mathcal{N}(\mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1), \sigma_2^2(1 - \rho^2))$$

Regresión y correlación

- La **curva de regresión**, que coincide con la recta de regresión de X_i/X_j , para $i, j = 1, 2$, $i \neq j$, viene dada por la **media de las distribuciones normales condicionadas**, anteriormente especificadas.

Más concretamente, viene dada por

$$x_i = \mu_i + \rho \frac{\sigma_i}{\sigma_j} (x_j - \mu_j), \quad i, j = 1, 2, \quad i \neq j.$$

- Equivalentemente, las **razones de correlación** coinciden con el **coeficiente de determinación** ρ^2 , ya que las curvas de regresión coinciden con las rectas de regresión.

- El **E.C.M.** asociado a la curva de regresión de X_i sobre X_j viene dado por $\sigma_i^2(1 - \rho^2)$, $i = 1, 2$, para cada $j = 1, 2$, con $i \neq j$.

Independencia \Leftrightarrow incorrelación \Leftrightarrow Σ Diagonal

Observamos que

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_1 \sigma_2 \rho \\ \sigma_1 \sigma_2 \rho & \sigma_2^2 \end{pmatrix},$$

matriz de covarianzas de una normal bidimensional, es no singular ($\rho^2 \neq 1$) y semidefinida positiva.

Es fácil comprobar que bajo el supuesto de normalidad bivariante:

$$\text{Independencia} \Leftrightarrow \text{Incorrelación} \Leftrightarrow \Sigma \text{ Diagonal}$$

De hecho la segunda equivalencia es evidente, y la primera es debida a que

$$\rho = 0 \Leftrightarrow f(x, y) = f_X(x)f_Y(y).$$

Importante: esta equivalencia no es válida si cada variable tiene distribución normal unidimensional pero la conjunta no.

Teorema para la función generatriz de momentos de la normal bivariante

Para $t = (t_1, t_2) \in \mathbb{R}^2$,

$$\begin{aligned} M_{X_1, X_2}(t_1, t_2) &= M_{X_1, X_2}(t) = E[\exp(\langle t, X \rangle)] \\ &= \exp\left(\langle \mu, t \rangle + \frac{t^\Sigma t^T}{2}\right), \\ &= \exp\left(t_1 \mu_1 + t_2 \mu_2 + \frac{t_1^2 \sigma_1^2 + t_2^2 \sigma_2^2 + 2t_1 t_2 \rho \sigma_1 \sigma_2}{2}\right). \end{aligned}$$

$$\begin{aligned} M_{X_1, X_2}(t_1, t_2) &= E[e^{(t \cdot X)}] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{(t_1 x_1 + t_2 x_2)} f_{X_1, X_2}(x_1, x_2) dx_1 dx_2 \\ &\stackrel{\text{parte de la parte}}{=} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{(t_1 x_1 + t_2 x_2)} f_{X_1 | X_2=x_2}(x_1) f_{X_2}(x_2) dx_1 dx_2 \\ &= \int_{-\infty}^{\infty} e^{(t_2 x_2)} f_{X_2}(x_2) \left[\int_{-\infty}^{\infty} e^{(t_1 x_1)} f_{X_1 | X_2=x_2}(x_1) dx_1 \right] dx_2 = \int_{-\infty}^{\infty} e^{(t_2 x_2)} M_{X_1 | X_2=x_2}(t_1) f_{X_2}(x_2) dx_2 \\ &= \int_{-\infty}^{\infty} e^{(t_2 x_2)} e^{\left(t_1(\mu_1 + \rho \frac{\sigma_1}{\sigma_2}(x_2 - \mu_2)) + \frac{t_1^2 \sigma_1^2 (1 - \rho^2)}{2}\right)} f_{X_2}(x_2) dx_2 \\ &= e^{\left(t_1(\mu_1 - \rho \frac{\sigma_1}{\sigma_2} \mu_2) + \frac{t_1^2 \sigma_1^2 (1 - \rho^2)}{2}\right)} \int_{-\infty}^{\infty} e^{(t_2 x_2 + t_1 \rho \frac{\sigma_1}{\sigma_2} x_2)} f_{X_2}(x_2) dx_2 \\ &= e^{\left(t_1(\mu_1 - \rho \frac{\sigma_1}{\sigma_2} \mu_2) + \frac{t_1^2 \sigma_1^2 (1 - \rho^2)}{2}\right)} M_{X_2}(t_2 + t_1 \rho \frac{\sigma_1}{\sigma_2}) \\ &= e^{\left(t_1(\mu_1 - \rho \frac{\sigma_1}{\sigma_2} \mu_2) + \frac{t_1^2 \sigma_1^2 (1 - \rho^2)}{2}\right)} \left(\frac{(t_2 + t_1 \rho \frac{\sigma_1}{\sigma_2})}{\sqrt{1 - \rho^2}} + \frac{(t_2 + t_1 \rho \frac{\sigma_1}{\sigma_2})^2 \sigma_2^2}{2} \right) \\ &= e^{\left(t_1 \mu_1 + t_2 \mu_2 + \frac{t_1^2 \sigma_1^2 + t_2^2 \sigma_2^2 + 2t_1 t_2 \rho \sigma_1 \sigma_2}{2}\right)}, \quad t_1, t_2 \in \mathbb{R}. \end{aligned}$$

Normalidad para combinaciones lineales de las componentes

Sea $X \sim \mathcal{N}_2(\mu, \Sigma)$. Se considera $A_{2 \times q}$ una matriz de rango máximo q , con $q = 1, 2$. Entonces:



$$Y = X A_{2 \times q} \sim \mathcal{N}_q(\mu A, A^T \Sigma A).$$

Demostración:

La demostración se obtiene de forma directa a partir del teorema anterior.

Sea $t \in \mathbb{R}^q$, entonces:

$$E[e^{t^T Y}] = E[e^{(t^T A^T) X^T}] = M_X(t^T A^T) = e^{(t^T A^T) \mu^T + \frac{(t^T A^T) \Sigma (t^T A^T)^T}{2}} = e^{t^T (\mu A)^T + \frac{t^T (A^T \Sigma A) t^T}{2}}$$

Dado que A es de rango máximo, $|A^T \Sigma A| \neq 0$, se deduce que $Y = X A \sim \mathcal{N}_q(\mu A, A^T \Sigma A)$.

Observación:

Se tiene que $Y = X A_{2 \times 2} = (a_{11} X_1 + a_{12} X_2, a_{21} X_1 + a_{22} X_2)$. De modo que cualquier vector bidimensional cuyas componentes sean combinación lineal de X_1 y X_2 , componentes de un vector normal bidimensional, de modo que la matriz A que define esta combinación sea no singular, tiene una distribución normal bidimensional.

TEMA 6

• Convergencia casi segura:

Casi seguro es consecuencia

$$X_n \xrightarrow{c.s.} X, \quad n \rightarrow \infty \Leftrightarrow P\left[\omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\right] = 1.$$

• Convergencia en probabilidad:

$$X_n \xrightarrow{P} X, \quad n \rightarrow \infty \Leftrightarrow \forall \varepsilon > 0, \lim_{n \rightarrow \infty} P[\omega : |X_n(\omega) - X(\omega)| \leq \varepsilon] = 1.$$

• Convergencia en Ley o en distribución:

$$X_n \xrightarrow{L} X, \quad n \rightarrow \infty \Leftrightarrow \lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x), \quad \forall x \in C(F_X),$$

siendo $C(F_X)$ el conjunto de puntos de continuidad de F_X .

Leyes de los grandes números

Sean $X_n, n \in \mathbb{N}$, variables aleatorias sobre el mismo espacio de probabilidad (Ω, \mathcal{A}, P) independientes. Adicionalmente, sea S_n la variable aleatoria que define las sumas parciales de la sucesión $\{X_n\}_{n \in \mathbb{N}}$, i.e.,

$$S_n = \sum_{i=1}^n X_i, \quad n \geq 1.$$

Se consideran dos sucesiones de números reales $\{a_n\}_{n \in \mathbb{N}}$ y $\{b_n\}_{n \in \mathbb{N}}$ tal que $b_n \uparrow \infty$.

- Ley débil de los grandes números respecto $\{a_n\}_{n \in \mathbb{N}}$ y $\{b_n\}_{n \in \mathbb{N}}$.** Se dice que la sucesión aleatoria $\{X_n\}_{n \in \mathbb{N}}$ satisface la ley débil respecto a $\{a_n\}_{n \in \mathbb{N}}$ y $\{b_n\}_{n \in \mathbb{N}}$ si

$$\frac{S_n - a_n}{b_n} \xrightarrow{P} 0.$$

- Ley fuerte de los grandes números respecto $\{a_n\}_{n \in \mathbb{N}}$ y $\{b_n\}_{n \in \mathbb{N}}$.** Se dice que la sucesión aleatoria $\{X_n\}_{n \in \mathbb{N}}$ satisface la ley fuerte respecto a $\{a_n\}_{n \in \mathbb{N}}$ y $\{b_n\}_{n \in \mathbb{N}}$ si

$$\frac{S_n - a_n}{b_n} \xrightarrow{c.s.} 0.$$

Teorema 1 Ley débil de Bernoulli

Sea $\{X_n\}_{n \in \mathbb{N}}$ una secuencia de variables aleatorias independientes e idénticamente distribuidas según una Bernoulli con parámetro p , i.e., $X_n \sim \mathcal{B}(1, p)$, para cualquier $n \in \mathbb{N}$, entonces

$$\frac{S_n - E[S_n]}{n} \xrightarrow{P} 0, \quad \text{y en consecuencia } \frac{S_n}{n} \xrightarrow{P} p,$$

Lema 0 Desigualdad de Chebychev

Sea X una v.a. con esperanza finita $E[X] < \infty$, entonces $\forall \varepsilon > 0$ se tiene que:

$$P[\{|X| \geq \varepsilon\}] = P[\omega : |X(\omega)| \geq \varepsilon] \leq \frac{E[X^2]}{\varepsilon^2}.$$

Observaciones:

- Si se considera la v.a. $X - E[X]$ se obtiene la versión clásica de esta desigualdad,

$$P[\{|X - E[X]| \geq \varepsilon\}] = P[\omega : |X(\omega) - E[X]| \geq \varepsilon] \leq \frac{E[(X - E[X])^2]}{\varepsilon^2} = \frac{\text{Var}(X)}{\varepsilon^2}.$$

- Si se toman complementarios también se puede escribir como sigue:

$$P[\{|X - E[X]| < \varepsilon\}] = P[\omega : |X(\omega) - E[X]| < \varepsilon] \geq 1 - \frac{\text{Var}(X)}{\varepsilon^2}.$$

Teorema 2 Ley débil de Khintchine

Sea $\{X_n\}_{n \in \mathbb{N}}$ una secuencia de variables aleatorias independientes e idénticamente distribuidas y existe $E[X_n] = \mu$, para cualquier $n \in \mathbb{N}$, entonces

$$\frac{S_n - E[S_n]}{n} \xrightarrow{P} 0, \quad \text{y en consecuencia } \frac{S_n}{n} \xrightarrow{P} \mu.$$

→ Diferencias entre convergencia en probabilidad y casi seguro

Demostración: se derivará para el caso particular en el que existe $E[X_n^2]$, para cualquier $n \in \mathbb{N}$. A partir de la desigualdad de Chebychev, para cualquier $\varepsilon > 0$, teniendo en cuenta que $X_i, i = 1, \dots, n$, son independientes y con la misma distribución, y por tanto,

$$\text{Var}(S_n) = \text{Var}(S_n - E[S_n]) = \text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i) = n\text{Var}(X_1).$$

Diferenciando el integrando

$$\begin{aligned} P\left(\left|\frac{S_n - E[S_n]}{n}\right| \geq \varepsilon\right) &\leq \frac{\text{Var}(S_n - E[S_n])}{\varepsilon^2 n^2} \\ &= \frac{n\text{Var}(X_1)}{n^2 \varepsilon^2} \rightarrow 0, \quad n \rightarrow \infty. \end{aligned}$$

En particular, dado que $E[S_n] = n\mu$, se obtiene $S_n/n \xrightarrow{P} \mu$, $n \rightarrow \infty$.

La ley débil de Bernoulli, se obtiene entonces considerando $\mu = p$.

Teorema 3 Primer teorema límite (Bernoulli)

Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias independientes e idénticamente distribuidas según una Bernoulli con parámetro p , i.e., $X_n \sim \mathcal{B}(1, p)$, para cualquier $n \in \mathbb{N}$, entonces

$$\frac{S_n - E[S_n]}{n} \xrightarrow{P} L.$$

Demostración: Se obtiene de forma directa del Teorema 2, dado que la convergencia en probabilidad implica la convergencia en Ley.

Teorema 4 Segundo teorema límite (De Moivre y Laplace)

Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias independientes e idénticamente distribuidas según una Bernoulli con parámetro p , i.e., $X_n \sim \mathcal{B}(1, p)$, para cualquier $n \in \mathbb{N}$, entonces

$$\frac{S_n - E[S_n]}{\sqrt{\text{Var}(S_n)}} = \frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{P} Z \sim \mathcal{N}(0, 1).$$

Teorema 5 Teorema límite de Lévy

Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias independientes e idénticamente distribuidas. Se tienen los siguientes límites en ley:

$$(i) \text{ Si } \exists E[X_1] \Rightarrow \exists E[X_n], \quad \forall n, \text{ se tiene } \frac{S_n - E[S_n]}{n} \xrightarrow{P} 0.$$

$$(ii) \text{ Si } \exists E[X_1^2] \Rightarrow \exists E[X_n^2], \quad \forall n, \text{ se tiene } \frac{S_n - E[S_n]}{\sqrt{\text{Var}(S_n)}} \xrightarrow{P} Z \sim \mathcal{N}(0, 1).$$

Teorema límite de Levy (Demostración)

La afirmación (i) se obtiene como consecuencia directa del Teorema 2 o bien, del Teorema 3.

La afirmación (ii) se demostrará para el caso particular, donde existe la función generatriz de momentos de las variables aleatorias de la sucesión $\{X_n\}_{n \in \mathbb{N}}$, definidas, todas ellas, sobre un intervalo común.

Se considera la secuencia

$$S_n^+ = \frac{S_n - E[S_n]}{\sqrt{\text{Var}(S_n)}} = \frac{S_n - np}{\sqrt{np(1-p)}},$$

donde $\sigma = \sqrt{\text{Var}(X_1)}$, para cualquier $n \in \mathbb{N}$. Se asume que $\mu = E[X_1] = 0$, para cualquier $n \in \mathbb{N}$. En caso contrario, se considera $\tilde{X}_n = X_n - \mu$, $n \in \mathbb{N}$.

Dado que $X_n, n \in \mathbb{N}$, son independientes e idénticamente distribuidas, con $\mu = 0$, la función generatriz de momentos

$$M_{S_n^+}(t) = \left[M_{X_1}\left(\frac{t}{\sqrt{np}}\right)\right]^n,$$

donde $M_{X_1} = M_{X_n} = M_X$, para todo $n \in \mathbb{N}$. Se considera ahora el desarrollo de Taylor de segundo orden de $M_X = E[\exp(tX)]$, $t \in (-a, b)$, $a, b \in \mathbb{R}_+$, que relaciona las derivadas en cero de la función generatriz de momentos con los momentos de X . Es decir,

$$\begin{aligned} M_X(t) &= 1 + \frac{dM_X(0)}{dt} t + \frac{1}{2} \frac{d^2M_X(0)}{dt^2} t^2 + t^2 e_2(t) \\ &= 1 + \frac{\sigma^2}{2} t^2 + t^2 e_2(t) = 1 + t^2 \left[\frac{\sigma^2}{2} + e_2(t)\right], \quad \lim_{t \rightarrow 0} e_2(t) = 0. \end{aligned}$$

Se considera ahora la correspondiente aproximación para $M_{S_n^+}(t)$. Más concretamente,

$$M_{S_n^+}(t) = \left(1 + \left(\frac{t}{\sqrt{np}}\right)^2 \left[\frac{\sigma^2}{2} + e_2\left(\frac{t}{\sqrt{np}}\right)\right]\right)^n = \left(1 + \frac{t^2}{n} \left[\frac{1}{2} + \frac{e_2\left(\frac{t}{\sqrt{np}}\right)}{\sigma^2}\right]\right)^n$$

Además,

$$t^2 \left[\frac{1}{2} + \frac{e_2\left(\frac{t}{\sqrt{np}}\right)}{\sigma^2}\right] \rightarrow \frac{t^2}{2}, \quad n \rightarrow \infty.$$

Aplicando el Lema 6, fijado un t , siendo

$$c_n = t^2 \left[\frac{1}{2} + \frac{e_2\left(\frac{t}{\sqrt{np}}\right)}{\sigma^2}\right], \quad c = \frac{t^2}{2}$$

se obtiene

$$M_{S_n^+}(t) \rightarrow \exp\left(\frac{t^2}{2}\right), \quad n \rightarrow \infty,$$

que corresponde a la función generatriz de momentos de una variable aleatoria normal con media cero y varianza uno. Por el teorema de continuidad para funciones generatrices de momentos se obtiene que

$$S_n^+ \xrightarrow{P} Z \sim \mathcal{N}(0, 1).$$